

Error Cuadrático Medio: cuantificando la eficiencia de un estimador

Inder Tecuapetla

8/03/2024

Sesgo

- ▶ Has oído hablar de **sesgo**?
- ▶ Qué significa **sesgo** para ti?
- ▶ Qué significa **sesgo** de un **estimador**?

Estimador

En estadística, decimos que un estimador es una **función** (regla de asociación) de los datos (muestra aleatoria) usada para **estimar** (aproximar) el valor de un parámetro de algún modelo

Estimador: Ejemplos

- ▶ Modelo normal (*la campana de Gauss*)
 - ▶ Estatura: Típicamente se asume que la estatura de una población se puede modelar con la campana de Gauss la cual está centrada en un valor μ (media) y su dispersión está determinada por la desviación estándar (σ).
 - ▶ Recuerdan *Dos estadísticas de uso común* en **introStats.pdf**?
Media y desviación estándar muestral

$$\bar{x}_n := \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma}_n^2 := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

- ▶ Sus contrapartes distribucionales son

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i, \quad \sigma_n^2 := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estimador: Ejemplos ...

2. Talla de calzado
3. Peso al nacer: El peso *normal* de un recién nacido está entre 2.5 y 3.5 kg.

Sesgo de un estimador

- ▶ Supongamos que ϑ_n (depende de los datos) aproxima/estima el valor de algún parámetro distribucional ϑ (e.g. la media o la varianza de una densidad normal).
- ▶ Si $E[\vartheta_n]$ (**valor esperado de ϑ_n**) es diferente a ϑ , entonces el estimador ϑ_n es sesgado.

Sesgo de un estimador: Math world vs real world

$E[\vartheta_n]$ es una cantidad asociada a la función de distribución del estimador ϑ_n , un ente matemático. Su contraparte empírico (en el mundo real) es el promedio aritmético (*la media*)


Error cuadrático medio (Mean Squared Error)

- ▶ ϑ_n denota un estimador del parámetro ϑ
- ▶ El **error cuadrático medio** del estimador ϑ_n se define como:

$$\begin{aligned}MSE(\vartheta_n) &:= E[(\vartheta - \vartheta_n)^2] \\&= E[(\vartheta - \mu_n + \mu_n - \vartheta_n)^2] \quad (\mu_n = E[\vartheta_n]) \\&= (\vartheta - \mu_n)^2 + E[(\vartheta_n - \mu_n)^2] \\&= \text{Sesgo}^2 + \text{Varianza}(\vartheta_n)\end{aligned}$$

- ▶ Hecho conocido:
 $\text{Varianza}(X) = E[(X - E(X))^2] = E[X^2] - E^2[X].$

Sesgo vs. Varianza



Sesgo grande y var. pequeña.



Sesgo grande y var. grande.



Sesgo pequeño y var. pequeña.



Sesgo pequeño y var. grande.

Estimador insesgado

- El estimador ϑ_n es insesgado para el parámetro ϑ si:

$$E[\vartheta_n] = \vartheta.$$

- Por ejemplo, en el modelo normal con media μ y varianza σ^2 , la media es un estimador insesgado de μ

$$E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n}(n\mu) = \mu.$$

Estimador insesgado para la varianza

- ▶ Sin embargo para la varianza, usando el estimador definido arriba tenemos:

$$\begin{aligned} E[\sigma_n^2] &= E \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right] = \frac{1}{n} E \left[\sum_{i=1}^n (X_i^2 - 2X_i \bar{X}_n + \bar{X}_n^2) \right] \\ &= \frac{1}{n} \sum_{i=1}^n E[X_i^2] - 2E \left[\left(\frac{1}{n} \sum_{i=1}^n X_i \right) \bar{X}_n \right] + E[\bar{X}_n^2] \\ &= \frac{1}{n} \sum_{i=1}^n E[X_i^2] - 2E[\bar{X}_n^2] + E[\bar{X}_n^2] = \frac{1}{n} \sum_{i=1}^n E[X_i^2] - E[\bar{X}_n^2] \\ &= \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2 \right) = \frac{n-1}{n} \sigma^2 \end{aligned}$$

Estimador insesgado para la varianza ...

Es decir,

$$\frac{1}{n} E\left[\sum_{i=1}^n (X_i - \bar{X}_n)^2\right] = \frac{n-1}{n} \sigma^2,$$

o de forma equivalente,

$$\frac{1}{n-1} E\left[\sum_{i=1}^n (X_i - \bar{X}_n)^2\right] = \sigma^2.$$

Por tanto, un estimador insesgado para σ^2 es:

$$\sigma_{n,I}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

MSE de un estimador insesgado

- ▶ Si ϑ_n es insesgado para ϑ , entonces

$$MSE(\vartheta_n) = \text{Varianza}(\vartheta_n)$$

- ▶ Es probable que hayan visto el uso del *RSME*:

$$RMSE(\vartheta_n) = \sqrt{MSE(\vartheta)},$$

que en el caso de un estimador insesgado es igual a la desviación estándar del estimador ϑ_n .

Aplicación de MSE en llenado de datos faltantes

- ▶ Práctica usando `mse_interpol.R`

EJERCICIO: Esquema de simulación

Hasta ahora has evaluado el desempeño de algunos métodos de llenado de datos faltantes cuando el conjunto de datos se mantiene fijo. Ahora vas a evaluar el desempeño de estos métodos cuando una misma máscara es aplicada a cada una de las variables.

- ▶ Aplica la máscara `masks[1,]` a cada una de las series de tiempo (`data1`, `data2`, ..., `data5`)
- ▶ A las series de tiempo resultante del inciso anterior, aplica cada uno de los métodos de llenado presentados en esta clase
- ▶ Existe un método que produzca los mejores resultados? Justifica tu respuesta.
- ▶ Repite los incisos anteriores usando cada una de las máscaras (`masks[2,]`, `masks[3,]`, ...)

EJERCICIO: Analizar desempeño sobre EVI

- ▶ Aplica la máscara `masks[1,]` a la serie de tiempo de EVI anualmente a partir de 2001 y hasta 2025
- ▶ A las series de tiempo resultante del inciso anterior, aplica cada uno de los métodos de llenado presentados en esta clase
- ▶ Existe un método que produzca los mejores resultados? Justifica tu respuesta.
- ▶ Repite los incisos anteriores usando cada una de las máscaras (`masks[2,]`, `masks[3,]`, ...)